

ZERO-COST ABSOLUTE

PQ AI Fabric

Cahier des charges technique v5

Infrastructure d'intelligence, d'outillage et d'orchestration pour les applications Élève et Administration de pq learn.

Version	5.0
Date	19 septembre 2026
Produit	pq learn
Contrainte	0 EUR de dépense obligatoire

Règle ultime : tout ce qui est essentiel doit fonctionner gratuitement. Le calcul lourd doit être local, communautaire, pré-calculé, mis en cache, différé ou désactivable - jamais transformé en dépense obligatoire.

Spécification destinée à l'audit, au développement, aux tests et au déploiement.

Table des matières

La table est générée automatiquement à partir des sections du cahier des charges.

Table des matières	2
0. Décisions exécutives	8
1. Vision	9
2. Périmètre	10
2.1 Inclus	10
2.2 Non-objectifs	10
3. Objectifs non négociables	11
4. Définition opérationnelle du coût zéro	12
4.1 Catégories financières	12
4.2 Ce que « gratuit » n'autorise pas	12
4.3 Budget technique	12
5. Échelle d'exécution Zero-Cost	13
6. Architecture logique	14
6.1 PQ AI Gateway	14
6.2 PQ Zero Cost Guard	14
6.3 PQ Capability Planner	14
6.4 PQ Technology Registry	14
6.5 PQ Smart Router	14
6.6 PQ Capability Composer	14
6.7 PQ Durable Workflow Engine	14
6.8 PQ Verification Layer	15
6.9 PQ Policy Engine	15
6.10 PQ Pedagogical Memory	15
6.11 PQ Knowledge Engine	15
6.12 PQ Compute Broker	15
6.13 PQ Offline Engine	15
6.14 PQ AI Fabric Control Center	15
7. Schéma obligatoire du Technology Registry	16
8. Stack de référence minimale	17
9. Profils d'appareils et packs	18

9.1 Device Tier L0 - très faible	18
9.2 Device Tier L1 - faible	18
9.3 Device Tier L2 - moyen	18
9.4 Device Tier L3 - puissant	18
9.5 Packs séparés	18
10. Intelligence conversationnelle et modèles	20
10.1 Rôle du LLM	20
10.2 Runtimes à inventorier	20
10.3 Providers externes	20
10.4 Structured outputs	20
11. Knowledge Engine et RAG	21
11.1 Corpus	21
11.2 Pipeline	21
11.3 Outils	21
11.4 Règles	21
12. Mémoire pédagogique et apprentissage adaptatif	22
12.1 Learner Model	22
12.2 Capacités	22
12.3 Outils candidats	22
13. Moteurs scientifiques	23
13.1 Mathématiques	23
13.2 Statistiques et optimisation	23
13.3 Physique et ingénierie	23
13.4 Chimie	23
13.5 Biologie	23
13.6 Terre, géographie et climat	24
13.7 Astronomie	24
14. Document Intelligence et OCR	25
14.1 Pipeline	25
14.2 Outils principaux	25
14.3 Règles	25
15. Images, vision, vidéo et rendu	26
15.1 Hiérarchie pédagogique	26
15.2 Vision	26
15.3 Images génératives	26
15.4 Vidéo	26
15.5 Pipeline média	26
15.6 Provenance	26

16. Audio, parole et langues	27
16.1 Stack	27
16.2 Langues	27
16.3 Accessibilité	27
17. Code Lab sécurisé	28
17.1 Niveaux d'exécution	28
17.2 Outils	28
17.3 Langages	28
17.4 Sécurité	28
18. Design et visualisation	29
18.1 Rendu Flutter	29
18.2 Dataviz	29
18.3 Diagrammes et whiteboards	29
18.4 3D et simulation	29
18.5 Design Engine	29
19. Données, cache, stockage et synchronisation	30
19.1 Stockage	30
19.2 Cache multi-niveaux	30
19.3 Offline et CRDT	30
19.4 Déduplication	30
20. Orchestration, files et résilience	31
20.1 Exigences	31
20.2 Candidats	31
20.3 Dégradation	31
21. Sécurité, confidentialité et protection des mineurs	32
21.1 Principes	32
21.2 Outils candidats	32
21.3 Prompt injection et RAG	32
21.4 Community compute	32
22. Licences et chaîne d'approvisionnement	33
22.1 Distinctions obligatoires	33
22.2 Registre de licence	33
22.3 Outils	33
22.4 Blocage	33
23. Standards éducatifs et portabilité	34
23.1 Standards prioritaires	34
23.2 Politique	34

24. Observabilité et évaluation	35
24.1 Télémétrie	35
24.2 Évaluation IA	35
24.3 Métriques	35
24.4 Benchmark PQ	35
25. Community Compute	36
25.1 Principe	36
25.2 Conditions	36
25.3 Statut	36
26. Modes de fonctionnement et dégradation	37
27. Présentation dans les applications	38
27.1 Application Élève	38
27.2 Application Administration	38
27.3 Notifications et diffusion	38
27.4 Distribution	39
28. Contrats API essentiels	40
28.1 Requête de capacité	40
28.2 Plan	40
28.3 Résultat	40
29. Structure logicielle indicative	41
30. Roadmap d'implémentation	42
Phase P0 - Audit et protection de l'existant	42
Phase P1 - Zero Cost Foundation	42
Phase P2 - Gateway et Router	42
Phase P3 - Planner, Composer et workflows	42
Phase P4 - Verification Layer	42
Phase P5 - Knowledge/RAG	42
Phase P6 - Scientific Engine	43
Phase P7 - Pedagogical Memory	43
Phase P8 - Offline Engine	43
Phase P9 - Documents, média, code et design	43
Phase P10 - Standards et Control Center	43
Phase P11 - Community Compute	43
Phase P12 - Scale	43
31. Critères d'acceptation	44
31.1 Coût	44
31.2 Fonctionnel	44
31.3 Qualité	44

31.4 Sécurité	44
32. Matrice de décision provisoire	45
33. Risques et réponses	46
34. Sources techniques de référence	47
35. Critère final de réussite	48
36. Certification de l'écosystème GitHub	49
36.1 Réponse formelle	49
36.2 Ce qu'est réellement un « outil GitHub »	49
37. Implémentation ajoutée au projet pq learn	50
37.1 Principe	50
37.2 Fichiers et contrats	50
37.3 Invariants exécutables	51
38. Couverture des 31 capacités	52
39. Catalogue GitHub contrôlé	54
39.1 Légende	54
39.2 Blocages explicites	59
40. Pipelines multimodaux cibles	60
40.1 Lire un fichier	60
40.2 Lire une image ou une vidéo	60
40.3 Lire et produire de l'audio selon le rôle	60
40.4 Produire une image dans les deux applications, une vidéo côté Administration	60
41. Plan d'adoption sans dette incontrôlée	61
42. Matrice de tests obligatoire	62
43. Décision v4 — remplacée par la section 49	63
44. Correction fonctionnelle v5 : droits Élève et Administration	64
44.1 Invariants désormais testés	64
45. Lecture vocale scientifique et mathématique	65
46. Fouille GitHub élargie et reproductible	66
46.1 Ce qui a réellement été fouillé	66
46.2 Limite honnête du mot « tous »	66
46.3 Licences observées	66

47. Index de découverte, shortlist et registre approuvé	67
47.1 Shortlist supplémentaire issue du relevé	68
48. Mise en oeuvre ajoutée dans la branche	71
49. Décision finale v5	72

0. Décisions exécutives


Cette version remplace le principe vague de « privilégier le gratuit » par une politique vérifiable.

Exigence	Décision obligatoire
Coût récurrent minimal	0 EUR
Carte bancaire nécessaire	Non
API payante critique	Interdite
Trial ou crédit temporaire critique	Interdit
Passage automatique au payant	Interdit
Fonctionnement sans fournisseurs externes	Obligatoire pour le coeur éducatif
Calcul lourd image/vidéo	Best effort local, communautaire, pré-calculé ou différé
Données sensibles d'élèves chez un tiers	Interdit par défaut
APK principal	Léger, avec packs optionnels
Mesure de la qualité	Benchmarks et tests de régression obligatoires
Licence inconnue	Blocage automatique

Le produit doit rester utile si, le même jour, tous les free tiers distants deviennent indisponibles.

1. Vision

PQ AI Fabric n'est pas une troisième application et n'est pas un nouveau chatbot. C'est une plateforme interne de capacités partagée par les agents Élève et Administration déjà existants.



Une demande peut mobiliser plusieurs outils : OCR, classification scolaire, recherche dans le programme, moteur symbolique, vérification d'unités, simulation, graphique et composition pédagogique. Le LLM n'est qu'une capacité parmi les autres.

Le système doit rechercher le meilleur **plan de capacités**, et non le plus grand modèle ni le plus grand nombre d'appels.

2. Périmètre

2.1 Inclus

- orchestration des agents existants ;
- questions, explications, corrections et révisions ;
- RAG sur les programmes et contenus pq learn ;
- calcul scientifique exact ou numérique ;
- documents, OCR, formules, tableaux et graphiques ;
- images, audio, animations et simulations ;
- génération et exécution sécurisée de code ;
- fonctionnement offline et synchronisation différée ;
- mémoire pédagogique et adaptation au niveau de l'élève ;
- routage entre appareils, moteurs locaux et ressources gratuites ;
- contrôle du coût, des licences, de la confidentialité et de la qualité ;
- centre de contrôle administratif ;
- standards éducatifs d'import, d'export et d'analytique.

2.2 Non-objectifs

- entraîner depuis zéro un modèle fondation géant ;
- promettre des images ou vidéos génératives illimitées sans GPU disponible ;
- contourner les quotas ou conditions d'un fournisseur ;
- envoyer silencieusement les données d'un mineur vers des services externes ;
- installer toutes les technologies inventoriées ;
- remplacer les agents existants sans audit ;
- confondre logiciel libre, modèle open-weight, free tier et calcul gratuit.

3. Objectifs non négociables

1. Le coeur éducatif doit fonctionner sans appel payant.
2. Le système doit d'abord rechercher une ressource validée, un cache ou une solution déterministe.
3. Un calcul exact ne doit pas être confié uniquement à un LLM.
4. Toute réponse critique doit être vérifiée par une règle, un solveur, une source ou un second moteur lorsque cela est possible.
5. Les agents existants doivent être augmentés, non dupliqués.
6. Les fonctionnalités offline doivent être conçues dès le départ.
7. Les modèles lourds doivent être distribués sous forme de packs optionnels.
8. Les téléphones faibles doivent bénéficier d'un parcours utile sans modèle lourd.
9. Chaque dépendance doit avoir une licence, une provenance et un statut explicites.
10. Chaque fournisseur externe doit avoir un fallback et un disjoncteur.
11. Les données d'élèves doivent être minimisées, pseudonymisées et gardées localement autant que possible.
12. La qualité doit être mesurée sur le programme camerounais et sur les appareils réellement ciblés.
13. La complexité et le poids de maintenance doivent être considérés comme des coûts.
14. Aucune fonctionnalité ne peut être déclarée terminée sans test réel.

4. Définition opérationnelle du coût zéro

4.1 Catégories financières

Chaque ressource reçoit exactement une catégorie :

Code	Catégorie	Utilisation dans le coeur gratuit
Z0	FOSS et usage commercial compatible	Autorisée après vérification
Z1	Logiciel auto-hébergeable gratuit	Autorisée si le matériel existe déjà
Z2	Calcul local sur appareil possédé	Autorisée avec consentement et limites
Z3	Ressource communautaire sans SLA	Optionnelle, jamais critique
Z4	Free tier récurrent sans carte	Optionnel avec fallback
Z5	Free tier avec carte ou risque de facturation	Interdit par défaut
Z6	Academic-only ou non-commercial	Interdit pour le produit commercial, sauf module séparé validé
Z7	Trial, crédit temporaire ou promotion	Interdit comme dépendance
Z8	Payant	Désactivé dans Zero-Cost Absolute
Z9	Licence ou coût inconnu	Bloqué jusqu'à revue

4.2 Ce que « gratuit » n'autorise pas

- créer plusieurs comptes pour contourner un quota ;
- masquer l'identité de pq learn à un fournisseur ;
- automatiser l'usage d'un service qui l'interdit ;
- utiliser un modèle dont la licence ne couvre pas l'usage commercial ;
- considérer une offre limitée dans le temps comme infrastructure permanente ;
- activer une facturation « au cas où » ;
- stocker des secrets de paiement dans le système.

4.3 Budget technique

Le budget monétaire du coeur est fixé à :

```
mandatory_monthly_cost = 0 EUR
mandatory_paid_api_calls = 0
mandatory_credit_card = false
automatic_paid_fallback = false
```

Le système suit malgré tout CPU, RAM, GPU, batterie, données mobiles, stockage et temps de calcul. Économiser ces ressources fait partie du Zero-Cost.

5. Échelle d'exécution Zero-Cost

Avant chaque opération coûteuse, le Router suit cet ordre :

1. **Exact cache** : réponse identique déjà validée.
2. **Semantic cache** : ressource équivalente et compatible avec le contexte.
3. **Bibliothèque pédagogique** : illustration, explication, simulation ou correction validée.
4. **Génération déterministe** : SVG, formule, graphique, moteur scientifique, template.
5. **Calcul local léger** : règles, FTS, embeddings, moteur scientifique.
6. **IA locale** : modèle téléchargé si l'appareil est compatible.
7. **Serveur déjà disponible** : ordinateur de l'administrateur ou infrastructure existante.
8. **Community compute opt-in** : noeud volontaire sécurisé, sans donnée personnelle brute.
9. **Free tier légitime** : seulement s'il est disponible et autorisé.
10. **File d'attente ou dégradation** : aucun basculement payant.

Le résultat final doit indiquer au système, sans forcément l'afficher à l'élève : origine, moteurs utilisés, version, coût monétaire, temps, confiance et vérifications effectuées.

6. Architecture logique

6.1 PQ AI Gateway

Point d'entrée commun aux agents existants. Il assure authentification, autorisation, validation des entrées, limitation de débit, traçage, récupération du contexte et normalisation des réponses.

6.2 PQ Zero Cost Guard

Composant bloquant placé avant toute exécution. Il doit :

- calculer le coût monétaire maximal d'un plan ;
- refuser tout plan supérieur à 0 EUR en mode strict ;
- bloquer les providers Z5 à Z9 ;
- vérifier qu'aucune clé de facturation n'est nécessaire ;
- empêcher un fallback payant configuré par erreur ;
- imposer un plafond de tokens, de temps, de RAM, de batterie et de réseau ;
- journaliser la raison de chaque autorisation ou refus ;
- proposer un plan gratuit alternatif ;
- fonctionner même si le LLM ou le Router est compromis.

Le Guard repose sur des règles déterministes. Un LLM ne peut pas modifier seul la politique financière.

6.3 PQ Capability Planner

Transforme une demande en graphe de tâches typé. Il identifie : intention, matière, classe, chapitre, modalités, précision requise, données nécessaires, contraintes offline, risques, niveau de l'élève et critères de réussite.

6.4 PQ Technology Registry

Catalogue machine-readable de tous les outils, modèles, providers, datasets et formats. Le Registry peut contenir plusieurs centaines de candidats, sans que ceux-ci soient installés.

6.5 PQ Smart Router

Choisit un moteur selon : capacité, qualité mesurée, licence, coût nul, appareil, réseau, confidentialité, quota, latence, cache, historique d'échec et impact énergétique.

6.6 PQ Capability Composer

Exécute les graphes de tâches : séquence, parallélisme, branches, retries, timeouts, compensation, transformation de formats, consensus, vérification et fusion finale.

6.7 PQ Durable Workflow Engine

Les travaux longs doivent survivre aux interruptions. Candidats à comparer : Temporal et Dapr Workflow. Pour un premier déploiement simple, ARQ, Dramatiq ou Celery avec Valkey peuvent suffire. Le choix final dépend de l'audit et du benchmark opérationnel.

6.8 PQ Verification Layer

Vérifie calculs, unités, schémas, syntaxe, code, citations, contraintes et provenance. Elle sépare explicitement : résultat calculé, contenu retrouvé, contenu inféré et contenu généré.

6.9 PQ Policy Engine

Centralise les règles de coût, rôle, confidentialité, licence et capacité. Open Policy Agent est candidat pour les politiques côté serveur ; des règles compilées/locales sont nécessaires sur mobile.

6.10 PQ Pedagogical Memory

Représente la progression, les notions maîtrisées, erreurs récurrentes, prérequis manquants, difficulté, langue, préférences d'explication et révisions. Ce n'est pas un simple historique de chat.

6.11 PQ Knowledge Engine

Ingestion, indexation, recherche hybride, reranking, assemblage de contexte, citations et contrôle des permissions sur les programmes, cours, exercices, corrigés et ressources validées.

6.12 PQ Compute Broker

Inventorie les ressources locales et volontaires, réserve les capacités, applique les quotas et choisit le lieu d'exécution sans transmettre inutilement les données.

6.13 PQ Offline Engine

Gère packs, téléchargements différentiels, compatibilité appareil, reprise de téléchargement, signatures, stockage local, mises à jour et suppression.

6.14 PQ AI Fabric Control Center

Interface Admin pour Registry, providers, modèles, licences, coûts évités, quotas, workflows, workers, cache, benchmarks, erreurs, packs offline et politiques.

7. Schéma obligatoire du Technology Registry

Chaque entrée doit contenir au minimum :

```
id: string
name: string
kind: library | model | provider | dataset | runtime | application
version: string
capabilities: []
platforms: []
languages: []
license:
  spdx_expression: string
  source_url: string
  commercial_use: true | false | unknown
  redistribution: true | false | unknown
  attribution_required: true | false
cost:
  class: Z0 | Z1 | Z2 | Z3 | Z4 | Z5 | Z6 | Z7 | Z8 | Z9
  requires_card: false
  auto_billing_possible: false
  mandatory_cost_eur: 0
runtime:
  local: true | false
  offline: true | false
  cpu: true | false
  gpu: true | false
  npu: true | false
  wasm: true | false
  webgpu: true | false
  min_ram_mb: integer
  min_storage_mb: integer
privacy:
  sends_data_external: true | false
  pii_allowed: false
quality:
  benchmark_version: string
  score: number
  confidence: number
operations:
  timeout_ms: integer
  fallback_ids: []
  status: ADOPT | TEST | RESERVE | REJECT
```

Une famille de modèles ne suffit pas : chaque checkpoint, quantification et licence doit avoir sa propre entrée.

8. Stack de référence minimale

Cette table définit des candidats initiaux, pas une obligation d'installer tous les outils.

Couche	Choix principal initial	Fallback ou candidat de test
UI mobile/web	Flutter, Dart	PWA web
API	FastAPI, Pydantic, OpenAPI	gRPC/Protobuf pour workers
Base serveur	PostgreSQL/Supabase existant	PostgreSQL auto-hébergé
Base locale	SQLite, Drift, FTS5	DuckDB pour analytique
Vecteurs	pgvector	Qdrant ou LanceDB si benchmark supérieur
Gateway modèles	LiteLLM auto-hébergé	adaptateurs natifs PQ
LLM local	llama.cpp ou MLC LLM	LiteRT-LM, ExecuTorch, ONNX Runtime
RAG	FTS5/BM25 + pgvector + reranker local	FAISS/Qdrant selon volume
Cache	SQLite local + Valkey serveur	cache sémantique PQ
Jobs	ARQ/Dramatiq/Celery	Temporal ou Dapr pour workflows complexes
Documents	Docling	PaddleOCR, Tesseract, OCRmyPDF
Audio	sherpa-onnx	whisper.cpp + Piper
Mathématiques	SymPy, NumPy, SciPy	SageMath, Maxima, Giac
Graphiques	ECharts/Flutter CustomPainter	Matplotlib, Plotly, Vega-Lite
Code web	Pyodide/JupyterLite	Wasmtime/WASI
Sandbox serveur	gVisor	Firecracker en phase avancée
Observabilité	OpenTelemetry	Prometheus, Grafana, Loki, Tempo
Évaluation	MLflow + tests PQ	Ragas, promptfoo, garak
Politiques	règles PQ + OPA	CEL selon contexte
SBOM/licences	CycloneDX/SPDX	ScanCode, ORT, Syft/Grype

9. Profils d'appareils et packs

9.1 Device Tier L0 - très faible

- cours, exercices et corrigés ;
- SQLite FTS5 ;
- calculs déterministes légers ;
- SVG et graphiques simples ;
- aucun modèle lourd ;
- recours au cache ou au serveur gratuit disponible.

9.2 Device Tier L1 - faible

- embeddings compacts ;
- OCR léger ;
- STT/TTS compact optionnel ;
- petit classifieur ;
- pas de diffusion d'image locale.

9.3 Device Tier L2 - moyen

- petit LLM quantifié ;
- RAG local partiel ;
- vision et audio offline ;
- graphiques et simulations interactives.

9.4 Device Tier L3 - puissant

- LLM local plus capable ;
- génération d'image locale compacte si testée ;
- multimodal local ;
- contribution communautaire explicite possible.

9.5 Packs séparés

- pq-core : cours, FTS, moteurs scientifiques essentiels ;
- pq-voice-fr, pq-voice-en, pq-voice-it ;
- pq-embeddings ;
- pq-llm-small ;
- pq-vision ;
- pq-science-advanced ;
- pq-media-creator ;
- packs scolaires par classe et matière.

Chaque pack doit être signé, versionné, compressé, reprenable, désinstallable et accompagné de sa licence.

10. Intelligence conversationnelle et modèles

10.1 Rôle du LLM

Le LLM assure principalement compréhension linguistique, planification assistée, explication, reformulation et composition pédagogique. Il ne remplace pas les solveurs, bases de données, règles ou moteurs de rendu.

10.2 Runtimes à inventorier

- llama.cpp et format GGUF ;
- MLC LLM pour Android, iOS, WebGPU et WASM ;
- LiteRT/LiteRT-LM ;
- ExecuTorch ;
- ONNX Runtime Mobile et Web ;
- WebLLM ;
- Transformers.js ;
- vLLM pour un serveur GPU déjà disponible ;
- Ollama uniquement comme outil local d'administration ou de développement ;
- OpenVINO pour matériel compatible.

Le benchmark doit mesurer démarrage, tokens/seconde, mémoire, batterie, chauffe, exactitude, tool calling et stabilité.

10.3 Providers externes

Gemini, Groq, Mistral, Cloudflare Workers AI, OpenRouter, Hugging Face Providers et autres offres gratuites peuvent être enregistrés en Z4 seulement si :

- aucune carte n'est exigée ;
- aucune facturation automatique n'est possible ;
- l'usage prévu respecte les conditions ;
- les quotas sont interrogés ou configurés ;
- une perte totale du provider est testée ;
- aucune donnée sensible brute n'est envoyée ;
- le système reste fonctionnel sans eux.

10.4 Structured outputs

Les plans, appels d'outils et résultats intermédiaires utilisent JSON Schema/Pydantic. Toute sortie structurée est validée avant exécution. Les erreurs de schéma déclenchent réparation limitée ou fallback, jamais exécution aveugle.

11. Knowledge Engine et RAG

11.1 Corpus

- programmes officiels camerounais ;
- arbre académique de pq learn ;
- cours, chapitres et leçons ;
- objectifs, compétences et prérequis ;
- exercices, corrigés et barèmes ;
- examens et épreuves ;
- ressources validées par l'administration ;
- métadonnées de classe, série, matière, module et unité d'apprentissage.

11.2 Pipeline

```
ingestion -> nettoyage -> découpage sémantique -> métadonnées  
-> index lexical + index vectoriel -> retrieval hybride  
-> filtrage par permissions -> reranking -> contexte  
-> génération -> vérification -> citations
```

11.3 Outils

- SQLite FTS5 et BM25 pour l'offline ;
- PostgreSQL + pgvector puisque Supabase est déjà présent ;
- FAISS pour certains packs locaux ;
- Qdrant, LanceDB ou Chroma uniquement après benchmark ;
- Tantivy, Lucene, Meilisearch ou Typesense pour des recherches spécialisées ;
- SentenceTransformers, FastEmbed, Transformers.js ou modèles ONNX pour embeddings locaux ;
- RDFLib, Oxigraph, Apache Jena, RDF/SPARQL et SHACL pour le graphe de connaissances si nécessaire.

11.4 Règles

- aucune réponse ne doit inventer un élément du programme ;
- chaque segment doit garder sa source, sa version et ses permissions ;
- les index doivent être reproductibles ;
- les embeddings de modèles différents ne doivent pas être mélangés ;
- la recherche hybride doit être comparée à lexical-only et vector-only ;
- le contenu produit par l'IA n'entre pas dans le corpus validé sans revue.

12. Mémoire pédagogique et apprentissage adaptatif

12.1 Learner Model

Le modèle de l'élève représente : classe, série, matières, objectifs, notions vues, maîtrise estimée, erreurs, temps de réponse, indices utilisés, difficulté, langue, révisions et consentements.

12.2 Capacités

- mastery estimation ;
- Bayesian Knowledge Tracing et alternatives ;
- FSRS pour répétition espacée ;
- Item Response Theory ;
- Computerized Adaptive Testing ;
- détection de prérequis manquants ;
- recommandations ciblées ;
- génération d'exercices gradués ;
- explications alternatives après échec ;
- tableaux de bord agrégés pour les enseignants.

12.3 Outils candidats

FSRS, pyBKT, bibliothèques IRT/CAT en Python ou R, OR-Tools pour planification, modèles statistiques classiques et règles pédagogiques explicables.

Les décisions importantes ne doivent pas dépendre uniquement d'un score opaque. L'élève et l'enseignant doivent pouvoir comprendre pourquoi une révision est proposée.

13. Moteurs scientifiques

13.1 Mathématiques

- SymPy, mpmath, NumPy, SciPy ;
- SageMath, Maxima, Giac/Xcas ;
- MathLive/Cortex Compute Engine ;
- GeoGebra et JSXGraph ;
- Matplotlib, Plotly, ECharts, D3, Vega-Lite ;
- R/ggplot2 et Julia ;
- Octave et Scilab ;
- Pint, Astropy Units ou unyt pour unités et dimensions ;
- Lean 4, Coq, Isabelle, Z3 ou cvc5 en TEST/RESERVE pour preuves et contraintes.

13.2 Statistiques et optimisation

- pandas ou Polars, statsmodels, scikit-learn ;
- R et Julia pour analyses spécialisées ;
- OR-Tools, HiGHS, COIN-OR, Ipopt, OSQP et GLPK ;
- PyMC ou alternatives uniquement pour modules avancés ;
- DuckDB et Parquet pour analytique locale.

13.3 Physique et ingénierie

- SymPy Mechanics, SciPy ODE/PDE, python-control ;
- ngspice, Qucs-S, Xyce ou SpiceOpus selon licence ;
- OpenModelica ;
- Open Source Physics ;
- moteurs ray-optics ;
- CoolProp pour thermodynamique si pertinent ;
- GNU Radio pour signaux et communications ;
- OpenFOAM, FEniCS, Elmer et CalculiX en RESERVE ;
- ROS 2, Gazebo et Webots en RESERVE pour robotique ;
- ns-3 et Mininet en RESERVE pour réseaux.

13.4 Chimie

RDKit, Open Babel, Cantera, Avogadro, Jmol/JSmol, Ketcher, données PubChem selon conditions, ASE et outils quantiques seulement pour extensions avancées.

13.5 Biologie

Biopython, scikit-bio, visualisation moléculaire, outils de séquences et bases ouvertes dont la licence et les conditions d'usage sont vérifiées.

13.6 Terre, géographie et climat

QGIS, GDAL, PROJ, Rasterio, xarray, MapLibre, Leaflet, CesiumJS, deck.gl, GeoJSON et OpenStreetMap. Les serveurs de tuiles publics ne sont pas considérés comme une infrastructure gratuite illimitée ; prévoir cache, packs offline ou hébergement autorisé.

13.7 Astronomie

Astropy, Skyfield, Stellarium et Celestia selon les modalités d'intégration.

14. Document Intelligence et OCR

14.1 Pipeline

```
photo/PDF/document -> validation -> antivirus -> correction image  
-> détection layout -> OCR -> tableaux/formules/images  
-> structure -> classification scolaire -> indexation -> RAG
```

14.2 Outils principaux

- Docling comme candidat principal pour parsing multi-format et PDF ;
- PaddleOCR et Tesseract comme OCR complémentaires ;
- OCRmyPDF pour rendre les PDF recherchables ;
- PDF.js, PDFium ou PDFBox selon plateforme ;
- Pandoc, Typst, Quarto et LaTeX ;
- LibreOffice headless ;
- docx.js, PptxGenJS et bibliothèques tableur ;
- Apache Tika ou Unstructured en fallback d'ingestion ;
- Surya, Marker, MinerU, TrOCR et pix2tex en TEST pour layout, manuscrit et math OCR.

14.3 Règles

- conserver le fichier original et sa somme de contrôle ;
- ne jamais considérer l'OCR comme vérité certaine ;
- relier chaque bloc extrait à sa page et sa boîte englobante ;
- signaler les formules incertaines ;
- permettre la correction humaine avant publication ;
- traiter les fichiers malveillants dans un environnement isolé.

15. Images, vision, vidéo et rendu

15.1 Hiérarchie pédagogique

1. réutiliser un asset validé ;
2. générer un SVG ou graphique exact ;
3. produire une animation/simulation déterministe ;
4. utiliser vision ou génération d'image locale ;
5. utiliser un noeud GPU volontaire ;
6. utiliser un free tier autorisé ;
7. mettre en attente si aucune ressource gratuite n'existe.

15.2 Vision

OpenCV, MediaPipe, ONNX Runtime, modèles de détection/segmentation validés, OCR spécialisé et modèles multimodaux compacts.

15.3 Images génératives

Diffusers et ComfyUI servent d'orchestrateurs locaux. Les familles FLUX, Stable Diffusion/SDXL, Qwen Image et futures familles sont des **candidats**, jamais une approbation globale. Chaque checkpoint doit passer : licence, commercial-use, poids, qualité éducative, sécurité, biais, RAM/VRAM et benchmark.

La génération lourde doit fonctionner en lot, en basse priorité, avec cache et déduplication. Une même demande normalisée ne doit pas être recalculée pour plusieurs élèves.

15.4 Vidéo

- priorité à Manim, FFmpeg, SVG animé, Canvas, WebGL/WebGPU, Three.js, Babylon.js, Godot et simulations interactives ;
- Wan, LTX Video, HunyuanVideo, CogVideoX et autres modèles restent en RESERVE/TEST ;
- aucune promesse de vidéo générative instantanée ou illimitée ;
- pré-génération Admin, file d'attente et réutilisation obligatoires.

15.5 Pipeline média

FFmpeg, libvips, ImageMagick, OpenColorIO si nécessaire, codecs libres compatibles, génération de miniatures, transcodage adaptatif et suppression des métadonnées sensibles.

15.6 Provenance

Chaque asset garde prompt, modèle, version, seed si applicable, licence, auteur humain, date, vérifications, hash et liens vers les sources. C2PA peut être évalué pour les médias générés.

16. Audio, parole et langues

16.1 Stack

- sherpa-onnx pour STT, TTS, VAD, identification de langue et fonctions audio locales ;
- whisper.cpp pour transcription offline ;
- Piper pour TTS local selon modèles et licences ;
- Silero VAD ;
- Web Audio API et Tone.js ;
- librosa, SciPy.signal, Essentia et aubio ;
- FluidSynth, Verovio et MuseScore pour musique et notation.

16.2 Langues

Français, anglais et italien sont prioritaires. Argos Translate, Marian, Bergamot, NLLB ou autres modèles peuvent être évalués pour traduction locale. Les accents camerounais et environnements bruyants doivent figurer dans le benchmark audio.

16.3 Accessibilité

Sous-titres WebVTT, réglage de vitesse, transcription, navigation clavier, contraste, textes alternatifs, modes dyslexie si validés, compatibilité lecteur d'écran et équivalents textuels pour les médias.

17. Code Lab sécurisé

17.1 Niveaux d'exécution

1. Pyodide/JupyterLite dans le navigateur pour Python compatible ;
2. WebAssembly/WASI avec Wasmtime pour tâches isolables ;
3. Judge0 ou Piston auto-hébergé après revue ;
4. conteneurs gVisor pour langages natifs ;
5. Firecracker en phase avancée si l'isolation multi-tenant l'exige.

17.2 Outils

Monaco ou CodeMirror, Tree-sitter, Language Server Protocol, compilateurs libres, tests unitaires, limites CPU/RAM/temps/processus/fichiers et réseau désactivé par défaut.

17.3 Langues

Python, C, C++, C#, Java, JavaScript/TypeScript, Kotlin, Rust, Go, Fortran, PHP, Ruby et autres uniquement lorsque le sandbox les supporte.

17.4 Sécurité

- système de fichiers éphémère ;
- aucune clé secrète visible ;
- réseau bloqué sauf allowlist ;
- image de runtime immuable ;
- limites strictes ;
- suppression après exécution ;
- journal technique sans code privé inutile ;
- analyse de malware et interdiction des exécutables téléchargés non validés.

18. Design et visualisation

18.1 Rendu Flutter

CustomPainter, SVG, Canvas, shaders validés et composants responsives. Les frameworks CSS ne concernent que les écrans Web et ne doivent pas alourdir l'application Flutter native.

18.2 Dataviz

Apache ECharts, D3, Plotly, Vega/Vega-Lite, Observable Plot, Matplotlib et ggplot2.

18.3 Diagrammes et whiteboards

Mermaid, Graphviz, PlantUML, D2, Cytoscape.js, TikZ, Excalidraw, Fabric.js, Konva, Paper.js, Rough.js, SVG.js et p5.js.

18.4 3D et simulation

Three.js, Babylon.js, VTK/vtk.js, Open3D, OpenCascade/FreeCAD, Blender, Godot, Flame, Box2D et Rapier.

18.5 Design Engine

Le moteur applique automatiquement hiérarchie, typographie, espacements, couleurs, responsive, impression, accessibilité et cohérence de marque. Il vérifie débordements, contrastes, lisibilité mobile et densité d'information.

19. Données, cache, stockage et synchronisation

19.1 Stockage

- PostgreSQL/Supabase pour données serveur existantes ;
- SQLite/Drift pour appareils ;
- pgvector pour embeddings serveur ;
- DuckDB, Polars, Arrow et Parquet pour analytique ;
- stockage objet S3-compatible ou MinIO seulement si une machine existe déjà ;
- export chiffré local comme sauvegarde gratuite.

19.2 Cache multi-niveaux

- cache mémoire ;
- cache SQLite appareil ;
- Valkey serveur ;
- cache exact ;
- cache sémantique ;
- cache d'assets ;
- cache de compilation/modèle ;
- invalidation par version de contenu, modèle et politique.

19.3 Offline et CRDT

Drift/SQLite pour données locales ; Automerge ou Yjs pour collaboration et fusion lorsque nécessaire. Les conflits pédagogiques sensibles restent soumis à une règle métier ou une revue humaine.

19.4 Déduplication

Les contenus, prompts normalisés et assets utilisent des hashes. Le système évite le double stockage et le double calcul sans confondre deux contextes pédagogiques différents.

20. Orchestration, files et résilience

20.1 Exigences

- idempotence ;
- retries bornés avec backoff ;
- timeouts ;
- annulation ;
- priorité Admin/Élève ;
- quotas par capacité ;
- dead-letter queue ;
- reprise après crash ;
- compensation des workflows ;
- stockage de l'état minimal ;
- aucun job infini.

20.2 Candidats

Valkey/Redis, NATS, ARQ, Dramatiq, Celery, Temporal et Dapr. Un seul chemin principal doit être adopté après audit. Kafka, Kubernetes, Ray, KServe ou infrastructures plus lourdes restent en RESERVE tant que l'échelle ne les justifie pas.

20.3 Dégradation

La perte d'un worker, d'un provider, d'Internet ou d'un modèle ne doit pas bloquer l'application. Le système répond avec une capacité réduite, met en attente ou explique honnêtement la limite.

21. Sécurité, confidentialité et protection des mineurs

21.1 Principes

- local-first pour données sensibles ;
- minimisation et finalité explicite ;
- pseudonymisation ;
- consentement et contrôle par rôle ;
- export, correction et suppression ;
- chiffrement en transit et au repos lorsque applicable ;
- séparation des environnements ;
- rotation des secrets ;
- audit logs sans contenu inutile ;
- rétention limitée.

21.2 Outils candidats

OPA pour politique, Presidio pour PII, ClamAV/YARA pour fichiers, Trivy/Grype pour vulnérabilités, gVisor/Wasmtime pour isolation, SOPS + age ou OpenBao pour secrets selon infrastructure.

21.3 Prompt injection et RAG

- considérer les documents comme données non fiables ;
- ne jamais exécuter une instruction trouvée dans un document ;
- séparer contenu, commande et politique ;
- allowlist des outils par rôle ;
- confirmer les actions sensibles ;
- tester les injections avec jeux adversariaux ;
- ne jamais exposer prompts système, clés ou données d'autres utilisateurs.

21.4 Community compute

Les workers ne reçoivent pas identité, coordonnées, historique complet ni fichier brut d'un élève. Les tâches sont minimisées, chiffrées lorsque possible, isolées et supprimées après expiration.

22. Licences et chaîne d'approvisionnement

22.1 Distinctions obligatoires

- logiciel open source ;
- modèle open-weight ;
- données ouvertes ;
- service gratuit ;
- contenu libre ;
- usage académique seulement.

Ces catégories ne sont jamais interchangeables.

22.2 Registre de licence

Pour chaque artefact : SPDX, URL officielle, texte/empreinte de licence, commercial-use, redistribution, dérivés, attribution, restrictions de données, date de revue et responsable.

22.3 Outils

CycloneDX ou SPDX pour SBOM, ScanCode Toolkit ou OSS Review Toolkit pour licences, Syft/Grype ou Trivy pour composants et vulnérabilités, Sigstore/Cosign pour signatures, safetensors pour modèles lorsque disponible, ModelScan/picklescan pour fichiers de modèles risqués.

22.4 Blocage

Une licence inconnue, incohérente ou incompatible force **status: REJECT** ou **status: TEST isolé**. Aucun agent ne peut approuver seul une licence.

23. Standards éducatifs et portabilité

23.1 Standards prioritaires

- QTI 3 pour questions, tests, scoring et résultats ;
- LTI 1.3 pour intégration future avec LMS ;
- Caliper Analytics ou xAPI pour événements pédagogiques ;
- H5P pour contenus interactifs ;
- Common Cartridge pour échanges de contenus ;
- WCAG 2.2 et bonnes pratiques WAI-ARIA pour accessibilité ;
- WebVTT pour sous-titres.

23.2 Politique

Le modèle interne de pq learn reste plus riche que les standards, mais chaque objet important possède une stratégie d'import/export. La certification payante éventuelle n'est pas une dépendance du fonctionnement gratuit.

24. Observabilité et évaluation

24.1 Télémétrie

OpenTelemetry pour traces, métriques et logs ; Prometheus pour métriques ; Grafana pour dashboards ; Loki/Tempo ou alternatives compatibles. Les données pédagogiques sensibles ne doivent pas être copiées dans les traces.

24.2 Évaluation IA

MLflow pour datasets, expériences, versions et feedback ; Ragas pour RAG et tool calling ; promptfoo, garak ou outils équivalents pour tests fonctionnels et adversariaux.

24.3 Métriques

- exactitude et conformité au programme ;
- réussite du retrieval et du reranking ;
- fidélité au contexte et citations ;
- exactitude des appels d'outils ;
- calculs et unités ;
- qualité pédagogique ;
- progression réelle de l'élève ;
- latence P50/P95/P99 ;
- RAM, CPU, GPU, batterie, réseau et stockage ;
- taux de cache ;
- taux de fallback ;
- indisponibilité provider ;
- coût monétaire observé et coût évité ;
- incidents de sécurité et licence.

24.4 Benchmark PQ

Au moins 1 000 scénarios versionnés, avec extension progressive : mathématiques, physique, chimie, informatique, langues, histoire-géographie, biologie, documents, images, audio, administration, offline, sécurité et coût zéro.

Comparer systématiquement :

```
LLM seul  
LLM + RAG  
LLM + outil déterministe  
LLM + plusieurs outils  
outils + vérification  
local vs serveur disponible vs free tier
```

25. Community Compute

25.1 Principe

Des ordinateurs volontaires peuvent exécuter des tâches anonymisées : pré-calcul d'illustrations, embeddings publics, génération média non sensible, benchmarks ou simulations.

25.2 Conditions

- consentement explicite ;
- pause immédiate ;
- limites CPU/GPU, batterie, température, horaires et réseau ;
- priorité à l'utilisateur de la machine ;
- sandbox ;
- tâches signées ;
- résultat vérifié ;
- aucune promesse de disponibilité ;
- aucune donnée privée brute ;
- réputation et révocation des workers.

25.3 Statut

Community Compute est RESERVE jusqu'à validation du coeur local, de la sécurité et de l'observabilité. BOINC, libp2p, WebRTC, Bacalhau et technologies apparentées peuvent être étudiés, mais aucun n'est adopté automatiquement.

26. Modes de fonctionnement et dégradation

Mode	Connectivité	Capacités garanties
Offline Basic	Aucune	cours, exercices, recherche locale, calculs, graphiques légers
Offline AI	Aucune	plus embeddings, voix, OCR, petit LLM selon appareil
Connected Free	Réseau	cache partagé, serveur disponible, free tiers optionnels
Community	Réseau	tâches lourdes anonymisées si workers disponibles
Admin Batch	Différé	génération de contenus et médias en lot

Si une capacité lourde manque, le système peut : réutiliser un asset, produire un schéma, réduire la résolution, différer, proposer une simulation ou annoncer honnêtement l'indisponibilité. Il ne doit jamais basculer silencieusement vers une facture.

27. Présentation dans les applications

27.1 Application Élève

- Demander à PQ ;
- Expliquer autrement ;
- Résoudre et vérifier ;
- Photographier une question ;
- Importer un document ;
- Tracer, simuler et manipuler ;
- Écouter et dicter ;
- Exécuter du code ;
- Réviser selon le Learner Model ;
- gérer les packs offline ;
- afficher clairement une file d'attente ou un mode réduit.

Le détail technique des providers reste caché, mais la provenance pédagogique et les citations doivent être accessibles.

27.2 Application Administration

PQ AI Fabric Control Center doit inclure :

- Technology Registry ;
- Zero Cost Guard ;
- modèles et packs ;
- providers et quotas ;
- licences/SBOM ;
- Planner/Router/Composer ;
- workflows, queues et workers ;
- cache et déduplication ;
- RAG et corpus ;
- benchmarks et régressions ;
- observabilité ;
- sécurité et incidents ;
- community compute ;
- coûts observés, coûts évités et preuve de facture nulle.

27.3 Notifications et diffusion

Web Push, notifications internes et mécanismes gratuits sont prioritaires. SMS et automatisation WhatsApp ne peuvent pas être des dépendances Zero-Cost ; prévoir partage manuel, deep links et modules optionnels désactivés.

27.4 Distribution

PWA et APK direct permettent une distribution sans boutique payante. Toute boutique, signature commerciale, domaine ou canal demandant un paiement reste optionnel et extérieur au coeur Zero-Cost.

28. Contrats API essentiels

28.1 Requête de capacité

```
{
  "request_id": "uuid",
  "actor": {"role": "student", "class": "Premiere C"},
  "intent": "solve_and_visualize",
  "modalities": ["text", "image"],
  "constraints": {
    "mandatory_cost_eur": 0,
    "offline_preferred": true,
    "external_pii_allowed": false
  }
}
```

28.2 Plan

```
{
  "tasks": [
    {"id": "ocr", "capability": "document.ocr"},
    {"id": "solve", "capability": "math.symbolic", "depends_on": ["ocr"]},
    {"id": "verify", "capability": "math.verify", "depends_on": ["solve"]},
    {"id": "render", "capability": "visual.plot", "depends_on": ["verify"]}
  ],
  "max_monetary_cost_eur": 0
}
```

28.3 Résultat

```
{
  "status": "completed",
  "artifacts": [],
  "provenance": [],
  "verification": {"status": "passed", "confidence": 0.96},
  "cost": {"monetary_eur": 0, "cpu_ms": 0, "network_bytes": 0}
}
```

29. Structure logicielle indicative

```
backend/  
  pq_ai_fabric/  
    gateway/  
    zero_cost_guard/  
    planner/  
    registry/  
    router/  
    composer/  
    workflows/  
    verification/  
    policy/  
    pedagogy/  
    memory/  
    knowledge/  
    scientific/  
      mathematics/  
      physics/  
      chemistry/  
      biology/  
      geography/  
      engineering/  
    media/  
      image/  
      video/  
      audio/  
      vision/  
    documents/  
    code_lab/  
    design/  
    offline/  
    providers/  
    compute/  
    community/  
    cache/  
    quotas/  
    observability/  
    security/  
    licensing/  
    benchmarks/  
    standards/
```

Cette arborescence est indicative. L'audit du repository réel décide des chemins finaux.

30. Roadmap d'implémentation

Phase P0 - Audit et protection de l'existant

- cartographier applications, backend, Supabase et agents ;
- exécuter les tests existants ;
- identifier doublons, dettes et contraintes ;
- établir une baseline de performance et de coût.

Phase P1 - Zero Cost Foundation

- Technology Registry ;
- catégories Z0-Z9 ;
- Zero Cost Guard ;
- contrats de capacités ;
- feature flags ;
- premiers tests prouvant l'absence d'appel payant.

Phase P2 - Gateway et Router

- abstraction providers ;
- LiteLLM ou adaptateurs PQ ;
- quotas, circuit breakers, fallback local ;
- structured outputs.

Phase P3 - Planner, Composer et workflows

- graphes typés ;
- exécution multi-outils ;
- retries, timeouts, annulation ;
- files et reprise.

Phase P4 - Verification Layer

- calculs, unités, citations, code, schémas ;
- score de confiance ;
- gestion explicite des divergences.

Phase P5 - Knowledge/RAG

- corpus validé ;
- ingestion ;
- recherche hybride ;
- citations ;
- benchmark de retrieval.

Phase P6 - Scientific Engine

- mathématiques, graphiques, unités ;
- physique et chimie prioritaires ;
- intégration progressive par matière.

Phase P7 - Pedagogical Memory

- modèle de maîtrise ;
- prérequis ;
- FSRS ;
- remédiation et tests adaptatifs.

Phase P8 - Offline Engine

- profils appareil ;
- packs ;
- synchronisation ;
- voix, embeddings et petit LLM optionnels.

Phase P9 - Documents, média, code et design

- OCR/document ;
- audio ;
- images déterministes ;
- Code Lab ;
- génération lourde uniquement après garde-fous.

Phase P10 - Standards et Control Center

- QTI, Caliper/xAPI et exports ;
- dashboards ;
- licences, SBOM et observabilité.

Phase P11 - Community Compute

- prototype non sensible ;
- sécurité ;
- benchmark ;
- déploiement seulement si bénéfice prouvé.

Phase P12 - Scale

- optimisation selon mesures ;
- aucun ajout d'infrastructure avant besoin démontré ;
- maintien du coût obligatoire à 0 EUR.

31. Critères d'acceptation

31.1 Coût

- 100 % des tests du coeur terminent avec `monetary_eur = 0` ;
- aucun secret de paiement n'existe ;
- aucun provider Z5-Z9 n'est accessible en mode strict ;
- la disparition de tous les free tiers laisse Offline Basic fonctionnel ;
- aucun fallback payant n'est possible, même après erreur.

31.2 Fonctionnel

- les agents existants utilisent le Fabric sans régression ;
- le Planner produit un graphe structuré ;
- le Composer exécute plusieurs moteurs ;
- les résultats déterministes sont vérifiés ;
- le RAG cite les contenus ;
- le mode offline couvre les parcours essentiels ;
- les packs sont installables et supprimables.

31.3 Qualité

- benchmark PQ versionné et reproductible ;
- aucune régression P0 non résolue ;
- qualité mesurée par classe et matière ;
- latence et mémoire compatibles avec au moins un appareil faible de référence ;
- les réponses incertaines l'indiquent.

31.4 Sécurité

- tests d'isolation du Code Lab ;
- fichiers malveillants bloqués ;
- aucune donnée sensible dans les traces ;
- licences et hashes vérifiés ;
- prompt injection et exfiltration testées ;
- suppression et export des données vérifiés.

32. Matrice de décision provisoire

Domaine	ADOPT initial	TEST	RESERVE	REJECT en Zero-Cost
RAG	FTS5, pgvector	Qdrant, LanceDB	graphe avancé	SaaS vectoriel payant
LLM local	llama.cpp	MLC, LiteRT, ExecuTorch, ONNX	vLLM GPU partagé	modèle/licence inconnus
Gateway	LiteLLM ou adaptateur PQ	MCP/A2A contrôlés	gateway entreprise	passerelle payante obligatoire
Documents	Docling, PaddleOCR, Tesseract	Surya, Marker, MinerU	VLM lourd	OCR payant critique
Audio	sherpa-onnx, whisper.cpp, Piper	modèles compacts alternatifs	génération audio lourde	TTS/STT payant critique
Images	SVG, graphes, Diffusers local	checkpoints validés	génération GPU communautaire	API image payante critique
Vidéo	FFmpeg, Manim, simulation	modèles locaux si GPU	community GPU	API vidéo payante critique
Code	Pyodide, Wasmtime	gVisor/Judge0	Firecracker	exécution non isolée
Observabilité	OpenTelemetry	MLflow/Ragas stack	services gérés	télémetrie payante critique
Standards	QTI, Caliper/xAPI	LTI, H5P	certification	format fermé obligatoire

Les statuts définitifs ne peuvent être attribués qu'après audit, revue de licence et benchmark.

33. Risques et réponses

Risque	Réponse obligatoire
Free tier supprimé	fallback local et test de panne totale
Téléphone trop faible	Offline Basic sans modèle lourd
Pas de GPU	SVG, simulation, pré-calcul, file d'attente
APK trop volumineux	packs optionnels et téléchargement différentiel
Modèle sous licence incompatible	blocage Registry
Réponse fluide mais fausse	Vérification Layer et confiance
Donnée élève exposée	local-first, redaction et politique
Trop d'outils	un primaire et un fallback par capacité
Community worker malveillant	tâches minimisées, sandbox et vérification
Maintenance excessive	critères d'adoption et retrait automatique
Coût caché	Zero Cost Guard, métriques et tests CI
Dépendance à un format	standards ouverts et export

34. Sources techniques de référence

Les versions, licences et conditions doivent être revérifiées au moment de l'adoption.

- ExecuTorch : <https://docs.pytorch.org/executorch/stable/index.html>
- LiteRT : <https://developers.google.com/edge/litert>
- MLC LLM : <https://github.com/mlc-ai/mlc-llm>
- ONNX Runtime Mobile : <https://onnxruntime.ai/docs/get-started/with-mobile.html>
- LiteLLM : <https://docs.litellm.ai/docs/>
- Temporal : <https://docs.temporal.io/>
- Dapr Workflow :
<https://docs.dapr.io/developing-applications/building-blocks/workflow/workflow-overview/>
- OpenTelemetry : <https://opentelemetry.io/docs/what-is-opentelemetry/>
- MLflow Evaluation : <https://mlflow.org/docs/latest/genai/eval-monitor/>
- Ragas : <https://docs.ragas.io/en/stable/>
- Open Policy Agent : <https://www.openpolicyagent.org/docs>
- gVisor : <https://gvisor.dev/docs/>
- Firecracker : <https://firecracker-microvm.github.io/>
- Wasmtime : <https://wasmtime.dev/>
- CycloneDX : <https://cyclonedx.org/>
- QTI : <https://www.1edtech.org/standards/qti>
- LTI : <https://www.1edtech.org/standards/lti>
- Caliper Analytics : <https://www.1edtech.org/standards/caliper>
- Supabase pgvector : <https://supabase.com/docs/guides/ai/vector-columns>
- DuckDB : https://duckdb.org/why_duckdb
- Automerge : <https://automerge.org/docs/hello/>
- sherpa-onnx : <https://github.com/k2-fsa/sherpa-onnx>
- Docling : <https://github.com/docling-project/docling>

35. Critère final de réussite

PQ AI Fabric v5 est réussi lorsque les agents existants peuvent comprendre une demande, la décomposer, retrouver les connaissances autorisées, composer plusieurs moteurs gratuits, vérifier les résultats, adapter l'explication à l'élève et produire une réponse multimodale de qualité, tout en restant utile sans Internet et sans aucun fournisseur externe.

Le succès n'est pas le nombre d'outils connectés. Le succès est la capacité à maintenir simultanément :

- **0 EUR de dépense obligatoire ;**
- **aucune dépendance payante critique ;**
- **qualité pédagogique mesurable ;**
- **fonctionnement offline réel ;**
- **sécurité et confidentialité des élèves ;**
- **résultats vérifiables ;**
- **architecture maintenable.**

Règle ultime : tout ce qui est essentiel doit fonctionner gratuitement. Tout ce qui exige exceptionnellement une forte puissance de calcul doit être local, communautaire, pré-calculé, mis en cache, différé ou désactivable - jamais transformé en dépense obligatoire.

36. Certification de l'écosystème GitHub

36.1 Réponse formelle

Oui : il existe suffisamment de projets GitHub sérieux pour couvrir la lecture et la génération de texte, documents, images, audio, musique et vidéo, ainsi que l'OCR, la recherche, le RAG, l'orchestration, les outils scientifiques, l'exécution de code, la sécurité et l'évaluation.

Non : « prendre absolument tous les GitHub » ne constitue ni une architecture ni une garantie de gratuité. GitHub contient des centaines de millions de dépôts, des forks, des projets abandonnés, des licences incompatibles, du code malveillant et des modèles dont la licence diffère de celle du code. PQ doit donc rendre **tout ajout possible**, mais n'activer que les composants passés par le Registry, le Zero Cost Guard, la revue de licence, le scan de sécurité et les benchmarks.

Au 2026-09-19, le catalogue machine-readable contient **31 capacités** et **100 composants** : **57 approuvés**, **38 conditionnels**, **2 à surveiller** et **3 bloqués**. Cette certification porte sur la politique de sélection et les métadonnées vérifiées à cette date ; elle ne remplace pas une revue juridique lors de chaque mise à jour de code ou de poids.


36.2 Ce qu'est réellement un « outil GitHub »

Objet	Rôle	Contrôle obligatoire
Dépôt de code	runtime, bibliothèque, application ou serveur	licence du code, activité, vulnérabilités, reproductibilité
Poids de modèle	capacité IA réelle	licence distincte, provenance, taille, langues, matériel
Agent	boucle de décision utilisant modèles et outils	permissions, budget, arrêt, observabilité
Skill	procédure réutilisable et contrainte	source, version, capacités autorisées
Serveur MCP	exposition standardisée d'outils	allowlist, authentification, schémas, sandbox
Adapter	contrat PQ vers un runtime	timeout, quotas, format, fallback, tests
Workflow	composition de plusieurs capacités	reprise, idempotence, traçage, compensation

37. Implémentation ajoutée au projet pq learn

37.1 Principe

Les chats et agents existants restent en place. La nouvelle couche n'est pas un chatbot supplémentaire : elle leur fournit un catalogue partagé et un planificateur déterministe. L'application Élève et l'application Administration utilisent le même Gateway et le même client Dart, sans intégrer directement 100 SDK différents.



37.2 Fichiers et contrats

Élément	Emplacement	Fonction
Catalogue JSON	gateway/config/capability_catalog.json	31 capacités, 100 composants, rôles, licences et contraintes
Modèles typés	gateway/app/capabilities/models.py	schéma Pydantic et invariants zéro coût
Registry/Planner	gateway/app/capabilities/registry.py	validation, filtrage, classement et dégradation
Routes partagées	gateway/app/capabilities/routes.py	inventaire et planification authentifiés
Valideur CI	gateway/scripts/validate_capability_catalog.py	échec si coût, carte, doublon ou capacité vide
Tests	gateway/tests/test_capability_registry.py	licences, GPU, offline, capacités inconnues
Client Flutter/Dart	packages/pq_ai_fabric_client/	contrat unique pour les deux applications

API exposée :

- GET /v1/capabilities : inventaire compact ;
- GET /v1/capabilities/{capability_id} : détail et providers ;
- POST /v1/capabilities/plan : plan compatible avec cible, matériel, réseau, GPU et licence.

Le Planner n'exécute encore aucun binaire tiers : il décide d'abord si un provider est admissible. Les adaptateurs d'exécution doivent être ajoutés par lots après test. Cette séparation empêche qu'un simple ajout au catalogue déclenche un téléchargement, une exécution ou une fuite de données.

37.3 Invariants exécutables

1. mandatory_cost_eur reste égal à zéro.
2. Les API payantes et cartes bancaires restent interdites.
3. Un provider bloqué ou en veille ne peut pas devenir core.
4. Un provider activé par défaut doit être approuvé.
5. Une licence conditionnelle exige un opt-in explicite.
6. Une demande sans GPU élimine les providers GPU-only.
7. Une demande offline élimine les providers nécessitant Internet.
8. Une capacité inconnue échoue explicitement.
9. Chaque capacité conserve une stratégie de dégradation gratuite.
10. Les poids et voix sont revus séparément du code.

38. Couverture des 31 capacités

Capacité	Entrées -> sorties	Candidats	Approuvés	Dégradation gratuite
text.generate	text -> text	12	1	template/cache; moteur déterministe; modèle local compact; file différée
vision.understand	image, text -> text, json	18	3	OCR local; détection classique; description indisponible explicitement
document.parse	document -> text, markdown, json	10	5	extracteur natif; OCR page par page; mise en revue humaine
ocr.extract	image, document -> text, json	8	4	Tesseract; saisie/revue humaine
image.generate	text, image -> image	6	2	SVG/Canvas déterministe; bibliothèque d'illustrations; file GPU différée
image.edit	image, text -> image	7	4	libvips/ImageMagick; édition manuelle; file GPU différée
image.segment	image, text -> mask, json	4	3	OpenCV/MediaPipe; revue manuelle
image.restore	image -> image	3	2	redimensionnement classique; original conservé
audio.transcribe	audio, video -> text, json	12	3	modèle ASR compact; file locale différée; saisie manuelle
audio.synthesize	text -> audio	7	3	voix système; modèle TTS compact; texte seul
audio.read_scientific_text	text, latex, mathml, formula -> audio, text, ssml	7	5	afficher l'expression originale; voix système après verbalisation vérifiée; texte verbalisé sans audio
audio.generate	text, audio -> audio	8	3	sons procéduraux; banque libre; file GPU différée
music.generate	text, audio -> audio	4	1	MIDI/procédural; banque libre; file GPU différée
audio.separate	audio -> audio	5	0	filtres FFmpeg; original conservé
video.understand	video, text -> text, json	12	7	ASR + images clés; métadonnées seulement; file différée
video.generate	text, image, audio -> video	10	5	Manim/SVG/Canvas; diaporama narré; file GPU différée

Capacité	Entrées -> sorties	Candidats	Approuvés	Dégradation gratuite
video.edit	video, audio, image -> video	6	2	FFmpeg/GStreamer; édition différée
media.transcode	audio, video, image -> audio, video, image	5	2	format original; traitement serveur différé
embeddings.generate	text, image -> vector	9	1	BM25/FTS5; modèle compact ONNX
retrieval.search	text, vector -> json, text	10	8	FTS5/BM25; pgvector; cache
agent.orchestrate	json, text -> json, text	9	8	workflow déterministe; file persistante; validation humaine
tool.protocol	json -> json	7	6	outil natif allowlisté; fonction indisponible explicitement
code.execute	code -> text, json, file	5	3	interpréteur navigateur; validation statique; exécution refusée
math.solve	text, formula -> json, formula, text	3	2	SymPy; calcul numérique; revue humaine
science.simulate	json, formula -> json, chart	10	4	moteur déterministe; simulation simplifiée
diagram.render	text, json -> image, svg	5	1	SVG/Canvas; rendu statique
3d.render	json, text -> 3d, image	6	1	Three.js/Babylon.js; schéma 2D
translation.local	text -> text	2	0	glossaire; mémoire de traduction; texte source
safety.scan	file, repository -> json	5	4	quarantaine; refus d'exécution
observability.evaluate	trace, dataset -> metrics, report	5	5	logs locaux; échantillonnage
sync.offline	json, file -> json, file	3	3	queue locale; export/import manuel

Une capacité affichant zéro provider approuvé n'est pas supprimée : elle reste disponible via une stratégie déterministe, un artefact validé, une revue de licence ou une file différée. Elle ne doit jamais basculer silencieusement vers un service payant.

39. Catalogue GitHub contrôlé

39.1 Légende

- **ADOPT** : utilisable après tests de version, checksum et benchmark.
- **REVIEW** : le code peut être libre mais le modèle, la voix, l'asset ou la configuration doit être validé.
- **WATCH** : projet non prioritaire, archivé ou insuffisamment stable.
- **BLOCK** : incompatibilité connue avec le produit commercial ou projet remplacé.
- **core/optional/experimental/rejected** : priorité d'intégration PQ, pas une note de popularité.

Runtimes LLM et multimodaux

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
llama.cpp	MIT	per-model	review	REVIEW	core
MLC LLM	Apache-2.0	per-model	review	REVIEW	optional
ONNX Runtime	MIT	per-model	review	REVIEW	core
ExecuTorch	BSD-3-Clause	per-model	review	REVIEW	optional
LiteRT	Apache-2.0	per-model	review	REVIEW	optional
WebLLM	Apache-2.0	per-model	review	REVIEW	optional
Transformers.js	Apache-2.0	per-model	review	REVIEW	optional
vLLM	Apache-2.0	per-model	review	REVIEW	optional
Ollama	MIT	per-model	review	REVIEW	optional
LocalAI	MIT	per-model	review	REVIEW	optional
Transformers	Apache-2.0	per-model	review	REVIEW	optional
Qwen3-VL	Apache-2.0	Apache-2.0	allowed	ADOPT	optional

Documents, OCR, image et vision

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
InternVL	MIT	per-model	review	REVIEW	experimental
LLaVA-NeXT	Apache-2.0	per-model	review	REVIEW	experimental
Docling	MIT	per-model	review	REVIEW	core
MarkItDown	MIT	per-model	review	REVIEW	optional
PaddleOCR	Apache-2.0	Apache-2.0/per-model	allowed	ADOPT	core
Tesseract OCR	Apache-2.0	Apache-2.0	allowed	ADOPT	core
MinerU	MinerU Open Source License	per-model	review	REVIEW	experimental
Surya	Apache-2.0	modified OpenRAIL-M	conditional	REVIEW	experimental
Apache Tika	Apache-2.0	same-as-code	allowed	ADOPT	optional
pypdf	BSD-3-Clause	same-as-code	allowed	ADOPT	optional
OpenCV	Apache-2.0	same-as-code	allowed	ADOPT	core
MediaPipe	Apache-2.0	per-model	review	REVIEW	optional
SAM 2	Apache-2.0/BSD-3-Clause	Apache-2.0	allowed	ADOPT	optional
Grounding DINO	Apache-2.0	Apache-2.0	allowed	ADOPT	optional
OpenCLIP	MIT	per-model	review	REVIEW	optional
Real-ESRGAN	BSD-3-Clause	per-model	review	REVIEW	optional
libvips	LGPL-2.1+	same-as-code	allowed	ADOPT	core
ImageMagick	ImageMagick License	same-as-code	allowed	ADOPT	optional
Diffusers	Apache-2.0	per-model	review	REVIEW	core
ComfyUI	GPL-3.0	per-model	review	REVIEW	optional
Qwen-Image	Apache-2.0	Apache-2.0	allowed	ADOPT	optional
FLUX.1 schnell	Apache-2.0	Apache-2.0	allowed	ADOPT	optional
FLUX.1 dev family	Apache-2.0	FLUX non-commercial	blocked	BLOCK	rejected
LlamaIndex	MIT	same-as-code	allowed	ADOPT	optional

Parole, audio et musique

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
whisper.cpp	MIT	MIT	allowed	ADOPT	core
faster-whisper	MIT	MIT/per-model	allowed	ADOPT	optional
sherpa-onnx	Apache-2.0	per-model	review	REVIEW	core
Vosk	Apache-2.0	Apache-2.0/per-model	allowed	ADOPT	optional
Kokoro	Apache-2.0	Apache-2.0	allowed	ADOPT	core
MeloTTS	MIT	MIT	allowed	ADOPT	optional
Piper	GPL-3.0	per-voice	conditional	REVIEW	optional
Bark	MIT	MIT	allowed	ADOPT	experimental
ACE-Step	Apache-2.0	Apache-2.0	allowed	ADOPT	optional
stable-audio-tools	MIT	per-model/gated	conditional	REVIEW	experimental
AudioCraft / MusicGen	MIT	CC-BY-NC-4.0	blocked	BLOCK	rejected
Demucs	MIT	per-model	review	WATCH	experimental
FFmpeg	LGPL-2.1+/GPL-2+ per build	same-as-build	conditional	REVIEW	core
GStreamer	LGPL-2.1+	per-plugin	conditional	REVIEW	optional
ffmpeg.wasm	MIT + FFmpeg build license	same-as-build	conditional	REVIEW	optional
LTX-Video	Apache-2.0	Apache-2.0/per-model	allowed	ADOPT	experimental

Vidéo et média

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
PySceneDetect	BSD-3-Clause	same-as-code	allowed	ADOPT	optional
Decord	Apache-2.0	same-as-code	allowed	ADOPT	optional
Wan 2.1	Apache-2.0	Apache-2.0	allowed	ADOPT	experimental
CogVideoX-2B	Apache-2.0	Apache-2.0	allowed	ADOPT	experimental
FramePack	Apache-2.0	per-model	review	REVIEW	experimental
Mochi 1	Apache-2.0	Apache-2.0	allowed	ADOPT	experimental
Open-Sora	Apache-2.0	per-checkpoint	review	WATCH	experimental
Manim Community	MIT	same-as-code	allowed	ADOPT	core

RAG, orchestration et protocoles

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
pgvector	PostgreSQL License	same-as-code	allowed	ADOPT	core
Qdrant	Apache-2.0	same-as-code	allowed	ADOPT	optional
sqlite-vec	MIT/Apache-2.0 dual	same-as-code	allowed	ADOPT	optional
FAISS	MIT	same-as-code	allowed	ADOPT	optional
LanceDB	Apache-2.0	same-as-code	allowed	ADOPT	optional
Sentence Transformers	Apache-2.0	per-model	review	REVIEW	core
Haystack	Apache-2.0	same-as-code	allowed	ADOPT	optional
LangGraph	MIT	same-as-code	allowed	ADOPT	core
Microsoft Agent Framework	MIT	same-as-code	allowed	ADOPT	optional
smolagents	Apache-2.0	same-as-code	allowed	ADOPT	optional
PydanticAI	MIT	same-as-code	allowed	ADOPT	optional
DSPy	MIT	same-as-code	allowed	ADOPT	experimental
AutoGen	MIT/CC-BY-4.0	same-as-code	allowed	BLOCK	rejected
MCP Servers	MIT	per-server	review	REVIEW	core
FastMCP	Apache-2.0	same-as-code	allowed	ADOPT	optional
Wasmtime	Apache-2.0 WITH LLVM-exception	same-as-code	allowed	ADOPT	core
Ragas	Apache-2.0	same-as-code	allowed	ADOPT	optional

Code, sciences, rendu et collaboration

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
Pyodide	MPL-2.0	package-dependent	conditional	REVIEW	core
JupyterLite	BSD-3-Clause	package-dependent	conditional	REVIEW	optional
gVisor	Apache-2.0	same-as-code	allowed	ADOPT	optional
Firecracker	Apache-2.0	same-as-code	allowed	ADOPT	experimental
SymPy	BSD-3-Clause	same-as-code	allowed	ADOPT	core
SciPy	BSD-3-Clause	same-as-code	allowed	ADOPT	core
RDKit	BSD-3-Clause	same-as-code	allowed	ADOPT	optional
Open Babel	GPL-2.0	same-as-code	conditional	REVIEW	optional
Cantera	BSD-3-Clause	same-as-code	allowed	ADOPT	optional
three.js	MIT	asset-dependent	review	REVIEW	core
Babylon.js	Apache-2.0	asset-dependent	review	REVIEW	optional
Godot Engine	MIT	asset-dependent	review	REVIEW	optional
Yjs	MIT	same-as-code	allowed	ADOPT	core
Automerge	MIT	same-as-code	allowed	ADOPT	optional

Sécurité, observabilité et qualité

Projet	Licence code	Licence modèle/artefact	Commercial	Statut	Niveau
Microsoft Presidio	MIT	per-model	review	REVIEW	core
Trivy	Apache-2.0	same-as-code	allowed	ADOPT	core
Syft	Apache-2.0	same-as-code	allowed	ADOPT	core
OpenTelemetry Python	Apache-2.0	same-as-code	allowed	ADOPT	core
MLflow	Apache-2.0	same-as-code	allowed	ADOPT	optional
Promptfoo	MIT	same-as-code	allowed	ADOPT	optional

Autres briques transversales

Projet	Type	Licence code	Commercial	Statut	Niveau
MathJax Source	math-accessibility-runtime	Apache-2.0	allowed	ADOPT	core
Speech Rule Engine	math-verbalization-engine	Apache-2.0	allowed	ADOPT	core
MathCAT	math-accessibility-engine	MIT	allowed	ADOPT	optional

39.2 Blocages explicites

Élément	Décision	Motif
AudioCraft/MusicGen	BLOCK	poids sous CC-BY-NC 4.0, non adaptés au produit commercial
FLUX.1 dev et dérivés non commerciaux	BLOCK	licence des poids non commerciale ; seul schnell Apache-2.0 est retenu
AutoGen	BLOCK pour nouveau développement	projet en maintenance ; Microsoft Agent Framework est le successeur retenu
Ultralytics	hors catalogue initial	AGPL-3.0 ou licence commerciale ; décision juridique/architecturale requise
Surya	REVIEW	poids sous licence modifiée avec conditions d'usage
MinerU	REVIEW	licence modifiée et modèles à contrôler séparément
Demucs	WATCH	dépôt archivé ; pas de dépendance de coeur

40. Pipelines multimodaux cibles

40.1 Lire un fichier

1. Détection MIME réelle et scan de sécurité.
2. Extraction native par type ; Docling/Tika/pypdf pour la structure.
3. OCR local PaddleOCR/Tesseract si le document est scanné.
4. Découpage, métadonnées, embeddings locaux et index pgvector/FTS.
5. Citations obligatoires vers page, bloc et version du fichier.

40.2 Lire une image ou une vidéo

1. Suppression des métadonnées non nécessaires et contrôle de taille.
2. OCR et vision classique avant VLM.
3. Échantillonnage vidéo, scènes, images clés et transcription audio.
4. VLM Apache-2.0 seulement si nécessaire et matériel compatible.
5. Résultat structuré, confiance, provenance et possibilité de revue.

40.3 Lire et produire de l'audio selon le rôle

1. FFmpeg pour normaliser le flux.
2. whisper.cpp/faster-whisper/Vosk pour la transcription locale.
3. Kokoro/MeloTTS ou voix système pour la synthèse.
4. Côté Élève : lecture vocale seulement ; côté Administration : ACE-Step peut produire une musique originale si le GPU existe.
5. Texte, partition, samples et licences conservés comme provenance.

40.4 Produire une image dans les deux applications, une vidéo côté Administration

1. Chercher d'abord une ressource validée ou produire SVG/Canvas/Manim.
2. Qwen-Image ou FLUX.1 schnell pour l'image générative, après benchmark.
3. LTX-Video, Wan 2.1, CogVideoX-2B ou Mochi comme options GPU expérimentales.
4. ComfyUI peut orchestrer les workflows locaux, avec noeuds API payants désactivés.
5. Si aucun GPU n'est disponible : file différée, animation déterministe ou contenu pré-calculé.

41. Plan d'adoption sans dette incontrôlée

Vague	Contenu	Condition de sortie
G0 - fondation	Registry, Planner, API, client Dart, tests	aucune régression, coût nul prouvé
G1 - lecture	fichiers, OCR, transcription, transcodage	corpus réel, CPU et offline validés
G2 - recherche	embeddings locaux, pgvector/FTS, citations	précision et isolation par profil
G3 - production légère	SVG, diagrammes et TTS scientifique	appareils faibles et accessibilité
G4 - génération GPU	images pour tous ; musique et vidéo Administration	worker volontaire, rôle, quota, licence, provenance
G5 - protocoles	MCP et adapters supplémentaires	allowlist, sandbox et tests d'injection
G6 - optimisation	benchmarks et remplacement des mauvais candidats	un primaire et un fallback par capacité

Le catalogue peut grandir sans limite artificielle, mais l'installation active doit rester petite. Une nouvelle technologie entre par pull request avec : licence, checksum, SBOM, propriétaire, capacité, adapter, matériel minimal, cas de test, benchmark, fallback et procédure de retrait.

42. Matrice de tests obligatoire

Axe	Test minimum
Zéro coût	panne totale des services externes ; aucune demande de carte ; aucun fallback payant
Licence	code et poids vérifiés séparément ; blocage si inconnu
Sécurité	fichiers hostiles, prompt injection, SSRF, archive bomb, secrets, sandbox
Mobile faible	L0/L1 sans modèle lourd, batterie et mémoire mesurées
Offline	lancement, cache, recherche, reprise et synchronisation
Qualité	français et programmes ciblés ; précision par matière et classe
Média	durée, résolution, latence, VRAM/RAM, provenance
Résilience	timeout, crash worker, reprise, dégradation et idempotence
Confidentialité	profil non autorisé refusé ; traces sans données sensibles
Applications	même contrat, autorisations distinctes Élève/Administration

43. Décision v4 — remplacée par la section 49

L'écosystème GitHub est **suffisant pour construire l'ensemble des capacités demandées**, mais il ne rend pas la puissance de calcul gratuite et il ne justifie pas d'installer tous les dépôts. La stratégie correcte est un **catalogue total, une activation sélective et des adaptateurs remplaçables**.

PQ peut donc intégrer progressivement texte, documents, images, audio, musique, vidéo, code et sciences sans API payante obligatoire. La promesse vérifiable reste : coeur utile sans Internet, aucune carte, aucun basculement payant, et refus automatique de toute licence ou provenance non validée.

44. Correction fonctionnelle v5 : droits Élève et Administration

Les deux applications partagent le même Gateway et le même client, mais **pas les mêmes autorisations**. Le rôle vient de l'identité authentifiée, jamais de la requête.

Capacité	Élève	Administration	Règle
Chat, génération et reformulation de texte	Oui	Oui	modèles locaux ou auto-hébergés validés
Lecture de PDF, documents et fichiers	Oui	Oui	scan, extraction, OCR, citations
Lecture/compréhension d'images	Oui	Oui	OCR puis vision si nécessaire
Lecture/compréhension de vidéos	Oui	Oui	scènes, images clés et transcription
Transcription d'un audio ou d'une vidéo	Oui	Oui	traitement local prioritaire
Création et édition d'images	Oui	Oui	provenance, quotas et matériel disponible
Diagrammes et vues 3D statiques	Oui	Oui	sorties image/SVG/3D, jamais vidéo côté Élève
Lecture vocale d'un texte ordinaire	Oui	Oui	TTS d'accessibilité et d'apprentissage
Lecture vocale scientifique et mathématique	Oui	Oui	verbalisation sémantique obligatoire avant TTS
Génération de sons créatifs	Non	Oui	audio.generate réservé au rôle admin
Génération musicale	Non	Oui	music.generate réservé au rôle admin
Génération vidéo	Non	Oui	video.generate réservé au rôle admin
Montage/transformation vidéo	Non	Oui	video.edit réservé au rôle admin


La synthèse vocale Élève transforme uniquement un contenu pédagogique en parole. Les vidéos et animations sont préparées dans l'Administration puis publiées aux élèves.

44.1 Invariants désormais testés

1. Côté Élève, `video.generate`, `video.edit`, `audio.generate` et `music.generate` ne retournent aucun provider.
2. Côté Administration, elles restent possibles si licence, matériel et coût zéro sont validés.
3. `image.generate` reste disponible à l'élève.
4. `diagram.render` produit `image/svg` ; `3d.render` produit `3d/image`.
5. Le serveur déduit le rôle authentifié et refuse toute promotion côté client.

45. Lecture vocale scientifique et mathématique

Un TTS brut ne doit jamais recevoir directement une formule ambiguë. La capacité `audio.read_scientific_text` est un pipeline en trois étapes obligatoires :



La formulation exacte de SRE ou MathCAT peut varier selon le jeu de règles. PQ ajoute donc une couche de normalisation et un corpus d'acceptation français. Exemples attendus :

Expression	Lecture attendue
$f(x)=x^2+3$	« f de x égale x au carré plus trois »
$\frac{a}{b}$	« a sur b »
$\sqrt{x+1}$	« racine carrée de x plus un »
$\int_0^1 x^2 dx$	« intégrale de zéro à un de x au carré, d x »
H ₂ SO ₄	« H deux S O quatre »

La qualité est validée sur fonctions, fractions, puissances, racines, intégrales, matrices, unités, chimie et ponctuation pédagogique. L'expression source, la verbalisation finale, la locale, le moteur et sa version sont conservés dans la trace ; l'audio seul n'est jamais la source de vérité.

46. Fouille GitHub élargie et reproductible

46.1 Ce qui a réellement été fouillé

Au 2026-09-19, le relevé reproductible contient :

Mesure	Résultat
Familles/requêtes de recherche	30
Résultats retournés avant déduplication	1940
Correspondances totales annoncées par GitHub, avec recouvrements	10091
Dépôts uniques conservés	1656
Dépôts hors catalogue d'exécution	1635
Dépôts archivés	57
Licence absente ou NOASSERTION	358

Familles interrogées : agents, asr, audio_generation, diarization, document_ai, document_parser, evaluation, image_edit, image_generation, local_api, local_llm, math, mcp, multimodal, music_generation, ocr, pdf, rag, sandbox, science, translation, tts, tts_multilingual, vector, video_generation, video_understanding, vision_language, voice, webgpu, workflow.

Le compte GitHub du projet (ahdybau1) est explicitement exclu. L'unité pertinente est le **dépôt**, pas le compte : un compte peut contenir des projets sans rapport, des forks, des données ou des démonstrations.

46.2 Limite honnête du mot « tous »

Il est techniquement impossible de certifier « tous les comptes GitHub » : l'inventaire change en continu, les dépôts privés sont inaccessibles, GitHub Search classe et plafonne les résultats, et les mots-clés produisent des faux positifs. Le présent audit est donc une **fouille large, datée et reproductible**, pas une prétention d'exhaustivité absolue.

Les 1656 entrées ne sont ni installées, ni téléchargées, ni exécutées. Elles alimentent un index de découverte. Les statistiques GitHub et licences déclarées sont des indices de tri, jamais une certification de sécurité ou de droit d'usage.

46.3 Licences observées

Licence déclarée	Dépôts
MIT	599
Apache-2.0	479
BSD-2/3-Clause	40
MPL-2.0	15
GPL-2.0/GPL-3.0	78
AGPL-3.0	66
UNKNOWN/NOASSERTION	358

47. Index de découverte, shortlist et registre approuvé

Trois niveaux empêchent l'installation aveugle :

Niveau	Taille actuelle	Peut être exécuté ?	Fonction
Discovery Index	1656 dépôts	Non	ne rien rater et relancer les audits
Shortlist d'expansion	50 dépôts	Non	candidats prioritaires à examiner
Capability Registry	100 composants	Seulement après décision du Planner	intégrations documentées et contrôlées

Le registre comprend désormais **31 capacités** et **100 composants** : **57 approuvés**, **38 conditionnels**, **2 à surveiller** et **3 bloqués**. Même un composant « approuvé » reste soumis au pin de version, au checksum, au scan et au benchmark avant activation réelle.

47.1 Shortlist supplémentaire issue du relevé

Famille	Dépôt	Licence GitHub déclarée	Étoiles au relevé	État PQ
Agents, mémoire et RAG	langchain-ai/langchain	MIT	146669	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	infiniflow/ragflow	Apache-2.0	90993	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	browser-use/browser-use	MIT	115284	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	Mintplex-Labs/anything-llm	MIT	66217	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	mem0ai/mem0	Apache-2.0	65643	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	crewAIInc/crewAI	MIT	58766	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	HKUDS/LightRAG	MIT	39761	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	microsoft/graphrag	MIT	36031	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	getzep/graphiti	Apache-2.0	31010	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	topoteretes/cognee	Apache-2.0	30839	DISCOVERY — désactivé, revue requise
Agents, mémoire et RAG	milvus-io/milvus	Apache-2.0	46160	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	ocrmypdf/OCRmyPDF	MPL-2.0	34803	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	JaidedAI/EasyOCR	Apache-2.0	30005	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	naptha/tesseract.js	Apache-2.0	38716	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	hiro-i-sora/Umi-OCR	MIT	47394	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	clovaai/donut	MIT	6926	DISCOVERY — désactivé, revue requise
Documents, PDF et OCR	deepdoctection/deepdoctection	Apache-2.0	3260	DISCOVERY — désactivé, revue requise

Famille	Dépôt	Licence GitHub déclarée	Étoiles au relevé	État PQ
Parole, transcription et audio	m-bain/whisperX	BSD-2-Clause	24124	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	modelscope/FunASR	MIT	20431	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	PaddlePaddle/PaddleSpeech	Apache-2.0	12685	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	speechbrain/speechbrain	Apache-2.0	11826	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	pyannote/pyannote-audio	MIT	10572	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	coqui-ai/TTS	MPL-2.0	46028	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	myshell-ai/OpenVoice	MIT	37581	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	QwenAudio/CosyVoice	Apache-2.0	23688	DISCOVERY — désactivé, revue requise
Parole, transcription et audio	open-mmlab/Amphion	MIT	10303	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	invoke-ai/InvokeAI	Apache-2.0	28247	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	AUTOMATIC1111/stable-diffusion-webui	AGPL-3.0	165020	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	Wan-Video/Wan2.2	Apache-2.0	17552	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	HKUDS/ViMax	MIT	12424	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	m87-labs/moondream	Apache-2.0	10050	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	Blaizzy/mlx-vlm	MIT	5511	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	deepseek-ai/DeepSeek-VL2	MIT	5375	DISCOVERY — désactivé, revue requise
Image, vidéo et vision	NVlabs/VILA	Apache-2.0	3863	DISCOVERY — désactivé, revue requise

Famille	Dépôt	Licence GitHub déclarée	Étoiles au relevé	État PQ
Traduction, mathématiques et sciences	argosopentech/argos-translate	MIT	6482	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	OpenNMT/CTranslate2	MIT	4678	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	davidcdc/Algebrite	MIT	1002	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	asc-community/Angouri Math	MIT	832	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	flintlib/flint	LGPL-3.0	653	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	K-Dense-AI/scientific-agent-skills	MIT	45621	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	gonum/gonum	BSD-3-Clause	8427	DISCOVERY — désactivé, revue requise
Traduction, mathématiques et sciences	stdlib-js/stdlib	Apache-2.0	5966	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	comet-ml/opik	Apache-2.0	22132	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	evidentlyai/evidently	Apache-2.0	7926	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	Giskard-AI/giskard-oss	Apache-2.0	5827	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	open-compass/VLMEval Kit	Apache-2.0	4401	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	judge0/judge0	GPL-3.0	4437	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	bytedance/deer-flow	MIT	82693	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	upstash/context7	MIT	62204	DISCOVERY — désactivé, revue requise
Évaluation, outils et sandbox	ChromeDevTools/chrome-devtools-mcp	Apache-2.0	52302	DISCOVERY — désactivé, revue requise

Cette shortlist n'accorde aucune confiance implicite. AGPL/GPL/MPL imposent une revue d'architecture et de distribution ; chaque modèle ou voix impose une revue d'artefact distincte ; les projets d'agents, MCP, navigation et sandbox reçoivent les contrôles réseau et permissions les plus stricts.

48. Mise en oeuvre ajoutée dans la branche

Élément	Résultat
Catalogue v2	rôles, 31 capacités, 100 composants, étapes de pipeline
Planner	refus par rôle et détection des étapes non couvertes
Route authentifiée	rôle dérivé du compte, jamais accepté depuis le client
Lecture scientifique	MathJax + Speech Rule Engine + MathCAT + TTS
Corpus français	fonctions, fractions, racines, intégrales, chimie et unités
Discovery Index	1 656 dépôts compactés, non exécutables
Shortlist	50 projets supplémentaires, tous désactivés
Validation	politique zéro coût, matrice des rôles et pipeline scientifique

Ordre d'intégration recommandé : lecture scientifique d'abord ; documents/OCR et transcription ensuite ; image côté deux applications ; génération audio/musique/vidéo uniquement dans les workers Administration ; agents, MCP et sandbox en dernier après durcissement.

49. Décision finale v5

Oui, l'écosystème libre et auto-hébergeable est suffisamment riche pour construire les capacités demandées. Non, aucun inventaire GitHub ne rend les calculs lourds illimités ou sans coût d'infrastructure, et aucun dépôt ne doit être branché automatiquement parce qu'il est public.

La cible confirmée est donc : **deux applications, un socle partagé, des droits différents**. L'Élève peut converser, générer du texte et des images, lire les fichiers et médias, et écouter une lecture scientifique correcte. L'Administration peut en plus générer et monter vidéos, sons et musiques. Le système ne dépend d'aucune API payante, d'aucune carte bancaire et d'aucun free tier externe critique.